

Bài nói thuyết trình CS221: phân tích chủ đề và cảm xúc bình luận YouTube tiếng Việt

Thời lượng: 10 phút 45 giây lời nói (1.667 chữ, nhịp trung bình 155 chữ mỗi phút), cộng 3 phút demo ở slide 12. Tổng khoảng 13 phút 45.

Người trình bày: một mình, 18 slide (14 slide chính, 1 slide câu hỏi, 3 slide phụ lục để dành).

Quy ước đọc: (*chữ in nghiêng trong ngoặc*) là chỉ dẫn thao tác, không đọc thành tiếng. Số thập phân viết bằng dấu phẩy cho dễ đọc, trên slide hiển thị dấu chấm. Ba slide phụ lục chỉ mở khi được hỏi.

Câu để lại: số đẹp thì dễ, số đọc lại được mới khó.

Slide 1. Trang bìa · 0:40

(*Đứng thẳng, nhìn thầy và cả lớp trước khi nhìn slide.*)

Thưa thầy và các bạn, em xin trình bày đề án của nhóm: phân tích chủ đề và cảm xúc bình luận YouTube tiếng Việt.

Hệ thống nhận bình luận dưới một video và trả về hai thứ. Người xem đang bàn chuyện gì, và họ khen hay chê.

Nhóm em có năm bạn, tên và mã số ở dưới. (*Không đọc danh sách, chỉ lướt tay qua.*)

Bài nói 10 phút, đi đúng năm bước của môn, sau đó em chạy ứng dụng 3 phút. Nếu thầy chỉ nhớ một câu, em mong thầy nhớ câu này: mọi con số trong bài đều đọc lại được từ thư mục `results`.

Slide 2. Bài toán · 0:45

Một video có vài nghìn bình luận, không ai đọc hết nổi. Đầu vào là bình luận thô. Đầu ra hai phần: các chủ đề người xem bàn tới, và phân bố cảm xúc ba lớp.

Dữ liệu này khó hơn văn bản báo chí. (*Chỉ dòng thứ tư.*) Một phần ba bình luận có emoji, chính xác 34,5%. Trung vị 52 ký tự, tức một câu ngắn, gần như không có ngữ cảnh. Và rất nhiều câu vừa khen vừa chê.

Thêm cái khó riêng của tiếng Việt: từ ghép không có ranh giới. Tách từ sai thì hỏng cả hai đầu ra. Nên em xin dành hẳn một slide cho bước đó.

Slide 3. Pipeline năm bước · 0:35

(*Chỉ vào sơ đồ, đi từ trái sang phải.*)

Nhóm em xếp đồ án theo đúng năm bước của bài 5: thu thập, tiền xử lý, biểu diễn, thuật toán, đánh giá. Mỗi bước một module, tên file ghi ngay trên sơ đồ.

Điểm khác so với một bài phân loại thuần nằm ở đây. (*Chỉ hộp số 3.*) Từ bước biểu diễn, pipeline tách hai nhánh: cảm xúc dùng TF-IDF và LinearSVC, chủ đề dùng vector câu và BERTopic. Hai nhánh gặp lại nhau ở ứng dụng, khi cảm xúc được hiện theo từng chủ đề.

Slide 4. Dữ liệu · 1:00

20.000 bình luận, hai cột: văn bản và nhãn. Nguồn là gói ATSH-NLP-20k, trích từ dự án nghiên cứu ATSH-ABSA ở trường mình. Nhóm em chỉ dùng cho học tập.

Ba lớp lệch nhau: tích cực gần một nửa, trung tính chỉ 17%. (*Chỉ hàng trung tính.*) Xin thầy nhớ con số 17%, nó quay lại ở phần kết quả.

Ba điều nhóm em nói thẳng. Một, tất cả bình luận đều về một chương trình, nên mô hình học cả tên thí sinh làm tín hiệu. Hai, tỉ lệ này do tác giả lấy mẫu lại: dữ liệu gốc khoảng 88% tích cực, tác giả giữ hết trung tính rồi lấy đúng 7.000 tiêu cực, nên con số mới tròn như vậy. Đây không phải tỉ lệ thật trên YouTube. Ba, đây là nhãn silver do một mô hình ngôn ngữ lớn gán, chưa ai kiểm từng dòng, và chính tác giả ghi trung tính là lớp nhiều nhất.

Slide 5. Tiền xử lý · 0:50

Bước này có ba quyết định.

Một, tách từ trước, hạ chữ thường sau. Nhóm em thử trực tiếp. (*Chỉ dòng thứ hai.*) Đưa "Đông Hùng hát" vào pyvi thì tên riêng thành một token; đưa bản đã hạ chữ thường thì tên bị tách làm hai. Phiên bản đầu của đồ án làm ngược thứ tự, nên chưa bao giờ ghép được tên riêng.

Hai, từ điển teencode. Bản cũ dịch "vcl" thành "rất", "ok" thành "tốt". Đó là mình gán sắc thái thay cho mô hình. Nhóm em bỏ hết, chỉ giữ sửa chính tả.

Ba, từ dừng. Danh sách có chữ "không", mà "không" lại là đặc trưng mạnh nhất của lớp tiêu cực, trọng số 2,93. Nên 236 từ dừng này chỉ đi vào bước chọn từ khóa chủ đề, không đụng tới bộ phân loại.

Slide 6. Đổi tiền xử lý thì được gì · 0:45

Bài 5 của môn có cặp thí nghiệm có tách từ và không tách từ. Nhóm em làm cặp tương tự cho hai phiên bản tiền xử lý của chính mình.

(*Chỉ hai dòng đầu.*) Mời thầy nhìn hai dòng đầu: 77,58% và 77,58%. Giống nhau đến hai chữ số thập phân.

Em xin nói thẳng: với bộ phân loại cảm xúc, đổi tiền xử lý không làm tăng điểm. Mọi chênh lệch đều nhỏ hơn một độ lệch chuẩn.

Nhóm em vẫn giữ bản mới, nhưng vì lý do khác: từ khóa chủ đề có tên riêng đúng, và từ điển không còn tự gán cảm xúc lên dữ liệu. Phần điểm tăng thật sự đến từ chỗ khác, em nói ở slide sau.

Slide 7. Biểu diễn · 0:50

Hai bài toán con cần hai cách biểu diễn.

Cảm xúc: TF-IDF unigram và bigram, 15.000 đặc trưng. Bigram ở đây là bắt buộc. *(Chỉ dòng thứ hai.)* Tiếng Việt đặt từ phủ định trước từ bị phủ định, nên nếu chỉ dùng unigram thì chữ "hay" sẽ kéo cả "không hay" về phía tích cực.

Chủ đề: mỗi bình luận đã tách từ thành một vector 768 chiều từ một mô hình Sentence-BERT tiếng Việt. Thẻ mô hình không ghi mô hình gốc, nhóm em đọc file `config.json` trên Hugging Face và suy ra nó tinh chỉnh từ PhoBERT-base. Hệ quả thực tế: PhoBERT học trên văn bản đã tách từ, nên bước pyvi phía trước vừa phục vụ từ khóa, vừa đúng định dạng mà mô hình nhúng mong đợi.

Slide 8. Quy trình đánh giá · 0:35

(Chỉ vào sơ đồ.)

Trước khi xem số, em xin nói cách chấm, vì đây là chỗ dễ tự lừa mình nhất.

Chia phân tầng 80 trên 20, hạt giống 42. Mọi lựa chọn, so bốn mô hình nền và dò tham số C, chỉ chạy bằng cross-validation năm phần trên 15.997 dòng huấn luyện. Tập kiểm tra 4.000 dòng để riêng ra, chấm đúng một lần.

Sau đó nhóm em chia lại với năm hạt giống khác để xem con số có ổn định không. Quy trình này là lý do nhóm em dám tin hai slide tiếp theo.

Slide 9. Mô hình cảm xúc · 0:55

Bốn mô hình nền, tất cả chấm bằng cross-validation trên tập huấn luyện.

(Chỉ dòng đầu.) Dòng đầu là mốc sàn: cứ đoán lớp đa số thì được 47,95%, nhưng macro-F1 chỉ 0,22. Đây là lý do nhóm em không lấy accuracy làm chỉ tiêu chính. Một mô hình bỏ hẳn lớp trung tính vẫn có accuracy đẹp.

Hai mô hình tuyến tính vượt Naive Bayes rõ.

(Chỉ dòng cuối.) Rồi nhóm em dò tham số C trên bốn giá trị. Từ C bằng 1 xuống 0,3, macro-F1 tăng từ 0,7054 lên 0,7180. Đây mới là phần tăng đo được của đồ án, không phải tiền xử lý.

Còn LinearSVC so với hồi quy logistic thì hơn đúng một phần nghìn, nhỏ hơn nhiều giữa các fold. Hai mô hình ngang nhau. Nhóm em giữ LinearSVC theo thiết kế ban đầu, không phải vì nó thắng.

Slide 10. Kết quả trên tập kiểm tra · 0:55

Kết quả trên 4.000 dòng để riêng, chấm đúng một lần: tỉ lệ dự đoán đúng 76,62%, macro-F1 0,7161. Chạy lại với năm hạt giống khác được 77,58%. Nên 76,62% là ước lượng thận trọng, không phải con số đẹp nhất nhóm em nhận ra.

(Chỉ hàng giữa của ma trận nhầm lẫn bên phải.) Mời thầy nhìn hàng giữa. Lớp trung tính chỉ nhận ra 54%, còn lại chia về hai phía: 203 dòng sang tiêu cực, 108 dòng sang tích cực.

Trong khi đó tiêu cực và tích cực gần như không nhầm sang nhau, chỉ 133 và 158 dòng trên gần 3.300 mẫu.

Gọn một câu: mô hình phân biệt khen với chê rất tốt, nhưng không chắc đâu là không khen không chê. Con số 17% quay lại đúng chỗ này.

Slide 11. Gom cụm chủ đề · 0:55

Sang nhánh chủ đề. BERTopic gồm ba bước: UMAP giảm 768 chiều xuống 5, HDBSCAN gom cụm theo mật độ, rồi c-TF-IDF chọn từ khóa.

(Chỉ hai dòng đầu.) Tham số mặc định không dùng được cho bình luận của cùng một chương trình: 49,2% rơi vào nhiễu. Đổi `min_samples` lên 5 thì hỏng theo hướng ngược lại, 91% dồn vào một cụm.

(Chỉ dòng ba.) Cấu hình 15 và 1 nằm giữa: 26 chủ đề, một phần ba nhiễu. Nhóm em chọn nó làm mặc định của ứng dụng, và bình luận nhiễu vẫn nằm trong bảng, không bị vứt đi.

Một phát hiện đáng nói: bật hay tắt từ dừng thì số chủ đề và tỉ lệ nhiễu không đổi một dòng nào, vì từ dừng nằm ở bước sau, khi HDBSCAN đã gom xong.

Xin nói rõ một giới hạn: bảng này chạy trên bình luận trong tập dữ liệu, không phải trên một video thật.

Slide 12. Demo ứng dụng · 3:00

Toàn bộ pipeline đóng thành một ứng dụng Streamlit. Bây giờ em chạy trực tiếp.

(Mở ứng dụng. Thanh bên: chọn Dữ liệu mẫu, 1.000 dòng. Bấm Bắt đầu phân tích.)

Trong lúc nó chạy, em nói qua sáu bước đang diễn ra: lấy dữ liệu, làm sạch, nhúng câu, gom cụm, phân loại cảm xúc, và tóm tắt tùy chọn. Bước nhúng câu lâu nhất, khoảng 15 giây cho 1.000 bình luận.

Ba nguồn dữ liệu: link YouTube cần API key, tệp CSV, và dữ liệu mẫu. Hai nguồn sau chạy được mà không cần khóa, nên thầy chấm bài không cần xin API key.

(Khi xong, mở tab Tổng quan.) Đây là số bình luận hợp lệ, số chủ đề, tỉ lệ nhiễu và tỉ lệ tích cực.

(Mở tab Chủ đề, chỉ vào một cụm.) Mỗi chủ đề có từ khóa và vài bình luận tiêu biểu. Bản đồ bên phải cho thấy cụm nào nằm gần cụm nào.

(Mở tab Cảm xúc.) Đây là chỗ hai nhánh gặp nhau: cảm xúc tách theo từng chủ đề, nên thấy được chủ đề nào bị chê nhiều nhất.

(Mở tab Dữ liệu, lọc một từ khóa.) Bảng lọc được theo chủ đề, cảm xúc, từ khóa, và tải về CSV.

Tab Mô hình chỉ đọc lại thẻ mô hình và mấy bảng em vừa trình bày, em xin không mở để tiết kiệm thời gian.

(Quay lại slide.)

Slide 13. Phân tích lỗi · 1:00

Nhóm em không dừng ở ma trận nhầm lẫn. Nhóm xuất toàn bộ 935 bình luận mà mô hình đoán sai, lấy mẫu phân tầng 150 dòng, rồi đọc tay từng dòng và xếp vào một hiện tượng.

(Chỉ hai hàng đầu.) Hai nhóm lớn nhất chiếm gần một nửa, và cùng nói một điều: TF-IDF thấy từ nhưng không thấy thái độ hướng về ai. Câu "tiếc cho team của Captain" mang từ buồn, nhưng là đồng cảm, không phải chê.

(Chỉ hàng ba.) Nhóm thứ ba là vừa khen vừa chê, và là nhóm lớn nhất của riêng lớp trung tính, 12 trên 50 dòng. Một nhãn cho cả câu thì buộc phải chọn một bên. Nên trung tính khó ngay từ định nghĩa, không phải chỉ khó vì ít dữ liệu.

Bảy dòng là nhãn gốc mà người đọc không đồng ý. Con số này đo trên mẫu lỗi, nên không suy ra được tỉ lệ nhãn sai của cả bộ dữ liệu.

Slide 14. Kết luận · 0:40

Ba điều nhóm em rút ra.

Một, pipeline đi đủ năm bước và ai cũng chạy lại được: một lệnh 12 giây sinh lại toàn bộ thư mục kết quả.

Hai, macro-F1 dừng ở 0,72, và thứ kéo nó xuống là lớp trung tính.

Ba, ở phần chủ đề, thứ đáng dò là tham số gom cụm, không phải danh sách từ dừng.

Ba việc tiếp theo, theo chi phí tăng dần: giữ emoji làm token, dùng vector câu cho phân loại, và tính coherence để chọn cấu hình bằng số đo.

Câu nhóm em muốn để lại: số đẹp thì dễ, số đọc lại được mới khó. Nhóm em chọn cái khó.

Slide 15. Câu hỏi · 0:20

Phần trình bày của em xin kết thúc ở đây. Mã nguồn, 146 kiểm thử và toàn bộ tệp kết quả nằm trong repo nộp kèm báo cáo.

Em xin cảm ơn thầy và các bạn, và sẵn sàng nhận câu hỏi.

(Dừng. Ba slide phụ lục phía sau chỉ mở khi được hỏi đúng chỗ.)

Phụ lục: ngân hàng câu hỏi

Mỗi câu trả lời dưới đây đều dẫn được về một tệp trong `results/` hoặc một dòng mã. Trả lời ngắn trước, chỉ mở slide phụ lục khi thầy hỏi tiếp.

Về cách đánh giá

- **"Vì sao lấy macro-F1 làm chỉ tiêu chính chứ không phải accuracy?"** → Vì ba lớp lệch nhau. Mô hình luôn đoán lớp đa số được accuracy 47,95% nhưng macro-F1 chỉ 0,2161. Macro-F1 tính trung bình F1 từng lớp nên lớp trung tính 17% có tiếng nói ngang hai lớp kia. Số ở `results/model_comparison.csv`.
- **"Chấm một lần trên tập kiểm tra thì có chắc không?"** → Chính vì chấm một lần nên mới chắc. Mọi lựa chọn đều làm bằng cross-validation trên tập huấn luyện, tập kiểm tra không tham gia. Sau đó nhóm em chia lại với năm hạt giống 0 đến 4, được 77,58% cộng trừ 0,44 và macro-F1 0,7200 cộng trừ 0,0037. Con số báo cáo 76,62% còn thấp hơn trung bình đó.
- **"Có bị rò rỉ dữ liệu không?"** → Không. TF-IDF được fit chỉ trên phần huấn luyện của từng fold, và một lần nữa trên tập huấn luyện đầy đủ trước khi chấm tập kiểm tra. Có kiểm thử cạnh chỗ này.
- **"Vì sao không báo độ lệch chuẩn cho hai mô hình đầu bảng?"** → MostFrequent và MultinomialNB là mốc tham chiếu, chạy một lượt. Hai mô hình tuyến tính được đưa vào so sánh thật nên có đủ trung bình và độ lệch chuẩn.

Về mô hình cảm xúc

- **"Vì sao LinearSVC mà không phải LogisticRegression?"** → Thật ra hai mô hình ngang nhau: chênh 0,0010 macro-F1, nhỏ hơn độ lệch giữa các fold. Nhóm em giữ LinearSVC theo thiết kế ban đầu và ghi rõ trong thẻ mô hình rằng đây là hòa, không phải thắng.
- **"Vì sao không tinh chỉnh PhoBERT cho phân loại luôn?"** → Đó đúng là hướng tiếp theo nhóm em đề xuất. Lý do chưa làm trong đợt này: phạm vi môn yêu cầu đi đủ năm bước với mô hình tuyến tính và báo được số so sánh, còn tinh chỉnh PhoBERT cần GPU và một vòng đánh giá riêng. Nhóm em không muốn báo một con số chưa chạy đủ năm hạt giống.
- **"Vì sao lớp trung tính kém đến vậy?"** → Ba lý do chồng lên nhau. Ít dữ liệu nhất, 17%. Nhãn silver nhiều nhất ở chính lớp này, tác giả bộ dữ liệu ghi vậy. Và khó ngay từ định nghĩa: trong 50 dòng trung tính bị sai mà nhóm em đọc tay, 12 dòng là câu vừa khen vừa chê, một nhãn cho cả câu thì buộc phải chọn một bên.
- **"Đặc trưng mạnh nhất là gì?"** → Của lớp tiêu cực là chữ "không", trọng số cộng 2,9301, rồi "chán", "không hay", "tức". Danh sách 25 n-gram đầu mỗi lớp ở `results/top_features.txt`.

- **"C bằng 0,3 dựa trên gì?"** → Lưới bốn giá trị, chấm bằng macro-F1 cross-validation trên tập huấn luyện: 0,1 cho 0,7124; 0,3 cho 0,7180; 1,0 cho 0,7054; 3,0 cho 0,6875. Bảng lưới được lưu trong `results/metrics.json`.

Về tiền xử lý

- **"Tách từ có thật sự cần không?"** → Cần, nhưng không phải vì điểm. Thí nghiệm A/B cho thấy điểm cảm xúc không đổi, 77,58% cả hai bản. Nó cần cho từ khóa chủ đề, vì tên riêng phải là một token, và vì mô hình nhúng gốc PhoBERT vốn học trên văn bản đã tách từ.
- **"Vi sao bỏ phần dịch tiếng lóng trong từ điển teencode?"** → Vì đó là gán nhãn trá hình. Đổi "vcl" thành "rất" hay "ok" thành "tốt" là mình quyết sắc thái thay cho mô hình, trước khi mô hình nhìn thấy dữ liệu. Nhóm em chỉ giữ phần sửa chính tả.
- **"Bỏ emoji đi có mất thông tin không?"** → Có, và nhóm em nói thẳng chỗ đó trong báo cáo. 34,54% bình luận chứa emoji. Giữ emoji làm token là thí nghiệm đầu tiên nhóm em đề xuất cho đợt sau.
- **"Vi sao từ dừng chỉ dùng cho chủ đề?"** → Vì "không" nằm trong danh sách từ dừng mà lại là đặc trưng mạnh nhất của lớp tiêu cực. Loại nó khỏi bộ phân loại là tự bỏ tín hiệu phủ định.

Về gom cụm chủ đề

- **"Vi sao chọn `min_topic_size` 15 và `min_samples` 1?"** → Bảng khảo sát năm cấu hình, ghi ở `results/topic_ablation.txt`. Mặc định đẩy 49,2% vào nhiều. `min_samples` bằng 5 gom 91% vào một cụm. Cấu hình 15 và 1 cho 26 chủ đề với 33,3% nhiều, cân bằng nhất trong năm cấu hình đã thử.
- **"33% nhiều có cao quá không?"** → Cao, và nhóm em không giấu. Nhưng HDBSCAN gán nhãn nhiều cho điểm không đủ mật độ, không phải vớt chúng đi: các bình luận đó vẫn nằm trong bảng dưới nhóm âm một và vẫn được chấm cảm xúc. Với bình luận ngắn của cùng một chương trình, có một tỉ lệ nhất định thật sự không thuộc cụm nào.
- **"Từ dừng ảnh hưởng thế nào tới cụm?"** → Không ảnh hưởng. Bật hay tắt cho phép gán chủ đề giống hệt từng dòng, chỉ từ khóa hiển thị đổi, vì từ dừng nằm ở bước c-TF-IDF, sau khi HDBSCAN đã gom xong. Đây là một trong những kết quả nhóm em thấy đáng nói nhất.
- **"Mô hình học được đặc trưng gì đáng ngờ không?"** → Có, và nhóm em nói trước. Mô hình học rằng ai nhắc quảng cáo thì thường chê, nhắc tên hai thí sinh thì thường khen. Đúng trong chương trình này, nhưng đó là đặc trưng của miền dữ liệu, không chuyển sang video khác được. Xem `results/top_features.txt`.
- **"Kết quả này có chuyển sang video khác được không?"** → Chưa biết, và nhóm em không dám nói là được. Bảng khảo sát chạy trên bình luận trong tập dữ liệu, không phải trên một video thật. HDBSCAN phụ thuộc mẫu: cùng tham số mặc định cho 3 chủ đề trên 1.000 dòng và 23 chủ đề trên 1.500 dòng.

Về dữ liệu

- **"Nhãn silver thì có đáng tin không?"** → Đáng tin ở mức của nó, và nhóm em ghi rõ giới hạn đó. Nhãn do một mô hình ngôn ngữ lớn gán theo đối tượng và khía cạnh rồi gộp, chưa ai kiểm từng dòng. Trong 150 dòng sai mà nhóm em đọc tay, 7 dòng người đọc không đồng ý với nhãn gốc. Con số đó đo trên mẫu lỗi nên không suy ra tỉ lệ cho cả bộ.
- **"Vì sao tiêu cực đúng 7.000 dòng tròn trĩnh?"** → Vì tác giả lấy mẫu lại. Dữ liệu gốc khoảng 88% tích cực; tác giả giữ hết trung tính, lấy đúng 7.000 tiêu cực rồi bù tích cực cho đủ 20.000. Ghi trong README của tác giả, nhóm em chép nguyên vào `data/README_ATSH_NLP_20k_goc.md`.
- **"Dữ liệu có được công bố lại không?"** → Không. Tác giả cho phép dùng cho mục đích học tập, không công bố lại. Repo và tệp CSV của nhóm em để riêng tư.

Về ứng dụng và kỹ thuật

- **"Chạy ứng dụng có cần API key không?"** → Chỉ nguồn link YouTube mới cần. Hai nguồn tệp CSV và dữ liệu mẫu chạy được ngay, nên thầy chấm bài không cần xin khóa.
- **"Tốn bao nhiêu quota YouTube?"** → Một lần chạy 1.000 bình luận tốn cỡ vài chục đơn vị cho `commentThreads.list`, cộng 1 đơn vị cho `videos.list`. Nhóm em chỉ gọi `comments.list` cho những chuỗi có nhiều hơn 5 phản hồi, tức là khi phần trả lời không nằm sẵn trong kết quả đầu.
- **"Phần tóm tắt bằng Ollama có bắt buộc không?"** → Không, là bước phụ, chạy cục bộ, tắt được. Chất lượng tiếng Việt của nó nhóm em chưa đánh giá và báo cáo ghi đúng như vậy.
- **"c-TF-IDF khác TF-IDF chỗ nào?"** → TF-IDF chấm từ theo từng văn bản. c-TF-IDF nối mọi bình luận của một cụm thành một văn bản rồi chấm theo cụm, nên nó trả lời câu "từ nào đặc trưng cho cụm này". (Nếu thấy hỏi tiếp, mở slide phụ lục B2 có ví dụ số.)
- **"Làm sao tái lập được kết quả?"** → Một lệnh `python src/train_sentiment.py` khoảng 12 giây sinh lại toàn bộ `results/` và `models/`. Ba script trong `experiments/` sinh lại ba bảng thực nghiệm. `pytest` chạy 146 kiểm thử khoảng 16 giây. Không lệnh nào cần mạng, trừ lần đầu tải mô hình nhúng về máy.
- **"Có bất kỳ kỹ thuật nào đáng kể không?"** → Có một cái nhóm em phải đọc mã nguồn thư viện mới ra. BERTopic mặc định `language="english"`; nếu không truyền mô hình nhúng vào, nó âm thầm xóa mọi ký tự ngoài bảng chữ cái tiếng Anh trước khi tính từ khóa, nên "không" thành "khng". Pipeline của nhóm em luôn truyền mô hình nhúng và có một kiểm thử cạnh chỗ đó. (Slide phụ lục B3.)

Ghi chú luyện tập

- Ba chỗ dễ vượt giờ: slide 4 dữ liệu, slide 11 gom cụm, và phần demo. Nếu slide 11 quá 1 phút thì bỏ đoạn phát hiện về từ dừng, để dành cho phần hỏi đáp.
- Nếu máy chiếu bị lệch màu hoặc phòng quá sáng, bản `report/CS221_slide.pptx` dựng lại được sang nền sáng bằng `--theme light`.

- Demo có thể hỏng vì mạng hoặc vì máy chưa tải mô hình nhúng. Chạy thử một lần trước buổi để mô hình nằm sẵn trong cache; nếu vẫn hỏng thì chuyển sang bày ảnh chụp trong docs/screenshots/ và nói theo đúng thứ tự tab.
- Câu chốt "số đẹp thì dễ, số đọc lại được mới khó" xuất hiện hai lần, ở slide 1 và slide 14. Đừng đổi chữ giữa hai lần.