

Phân tích chủ đề và cảm xúc bình luận YouTube tiếng Việt

Đề án môn: Xử lý ngôn ngữ tự nhiên

Giảng viên hướng dẫn: **TS. Đặng Văn Thìn**

NHÓM THỰC HIỆN

Lê Phú Hiếu · 26410038 · LT.K2026.1.TTNT

Nguyễn Thanh Duy · 26410030 · LT.K2026.1.TTNT

Nguyễn Thanh Phong · 26410090 · LT.K2026.1.TTNT


Nguyễn Thị Mai Thi · 26410117 · LT.K2026.1.TTNT

Hồ Viết Trịnh · 26410140 · LT.K2026.1.TTNT

Hàng nghìn bình luận, hai câu hỏi

- **Đầu vào:** toàn bộ bình luận dưới một video YouTube tiếng Việt
- **Đầu ra 1:** các chủ đề người xem bàn tới, mỗi chủ đề là một nhóm từ khóa và vài bình luận tiêu biểu
- **Đầu ra 2:** phân bố cảm xúc theo ba lớp tiêu cực, trung tính, tích cực
- **Vì sao khó:** teencode (ko, đc, j), không dấu, emoji trong 34.5% bình luận, câu ngắn (trung vị 52 ký tự), châm biếm và vừa khen vừa chê
- Tiếng Việt không có khoảng trắng giữa các từ, nên tách từ quyết định chất lượng cả hai đầu ra

Pipeline năm bước theo bài giảng, mỗi bước một module

**Chú giải màu**

- Dữ liệu vào
- Bước cơ học
- Biểu diễn và mô hình
- Kết quả và ứng dụng

20.000 bình luận có nhãn về một chương trình

Nhãn	Số dòng	Tỉ lệ
Tiêu cực (0)	7.000	35,0%
Trung tính (1)	3.409	17,0%
Tích cực (2)	9.591	48,0%
Tổng, sau tiền xử lý	19.997	3 dòng rỗng

- Gói ATSH-NLP-20k, dự án ATSH-ABSA (UIT); bình luận về Anh Trai Say Hi mùa 1, tập 1 đến 14
- Nhãn silver do mô hình ngôn ngữ lớn gán theo đối tượng và khía cạnh rồi gộp; chưa kiểm tay, trung tính nhiều nhất
- Tác giả lấy mẫu lại từ dữ liệu gốc khoảng 88% tích cực; tỉ lệ nhãn không phải tỉ lệ thật trên YouTube
- Một chương trình duy nhất; chỉ dùng cho học tập, không công bố lại

Tách từ trước, hạ chữ thường sau

- **Thứ tự trong mã:** chuẩn hóa NFC, bỏ URL, bỏ ký hiệu @ và #, thay dấu câu và emoji bằng khoảng trắng, rút chữ lặp (luônnnnn thành luôn), chuẩn hóa teencode, tách từ bằng pyvi, cuối cùng mới hạ chữ thường
- **Vì sao thứ tự đó:** pyvi phân biệt chữ hoa khi ghép tên riêng. *Đông Hùng hát* cho *Đông_Hùng hát*; đã hạ chữ thường thì thành ba token rồi
- Từ điển teencode chỉ sửa chính tả (*ko, hok, không thành không*), không dịch tiếng lóng sang từ cảm xúc. Bản cũ có ok thành tốt, vcl thành rất: đó là gán nhãn trước khi mô hình học
- 236 từ dừng chỉ dùng cho từ khóa chủ đề, vì *không* nằm trong danh sách và là đặc trưng mạnh nhất của lớp tiêu cực (+2,93)

Đổi tiền xử lý không đổi điểm cảm xúc, nhưng đổi từ khóa chủ đề

Tiền xử lý	C	Tỉ lệ dự đoán đúng	Macro-F1	F1 trung tính
Cũ	0,3	77,58% ± 0,47	0,7199 ± 0,0052	0,5218
Mới	0,3	77,58% ± 0,50	0,7200 ± 0,0041	0,5222
Cũ	1,0	76,61% ± 0,40	0,7079 ± 0,0052	0,5004
Mới	1,0	76,57% ± 0,43	0,7075 ± 0,0053	0,5007

- Cùng TF-IDF và LinearSVC, năm hạt giống chia tập (0 đến 4), trên bình luận của tập dữ liệu
- Mọi chênh lệch nằm trong một độ lệch chuẩn: với bộ phân loại, thay đổi là trung tính
- Giữ bản mới vì tên riêng thành một token trong từ khóa chủ đề và từ điển không áp sắc thái lên dữ liệu

TF-IDF cho cảm xúc, vector câu 768 chiều cho chủ đề

- **Cảm xúc:** TF-IDF unigram và bigram, 15.000 đặc trưng, sublinear_tf
- Bigram là bắt buộc vì phủ định đứng trước từ bị phủ định: *không hay, không thích* là đặc trưng của lớp tiêu cực; *hay mà, hay nhưng* là đặc trưng của lớp trung tính
- **Chủ đề:** mỗi bình luận đã tách từ thành một vector 768 chiều từ keepitreal/vietnamese-sbert (Sentence-BERT tiếng Việt; theo config.json trên Hugging Face, mô hình được tinh chỉnh từ PhoBERT-base, nên cần tách từ trước)
- Từ khóa của mỗi cụm chọn bằng c-TF-IDF: từ nào nhiều trong cụm này, ít ở cụm khác thì lên đầu (ví dụ số ở phụ lục)

Chọn trên tập huấn luyện, chấm một lần trên tập kiểm tra



Chú giải màu

■ Dữ liệu
 ■ Bước cơ học
 ■ Chọn mô hình
 ■ Kết quả
 ■ Đánh giá và kiểm tra
 ■ Nguyên tắc cần giữ

Bốn mô hình nền, dò C, chỉ trên tập huấn luyện

Mô hình	Tỉ lệ dự đoán đúng (CV)	Macro-F1 (CV)
MostFrequent (đoán lớp đa số)	47,95%	0,2161
MultinomialNB	73,82%	0,5620
LogisticRegression	76,25%	0,7170 ± 0,0054
LinearSVC, C = 1	76,56%	0,7054 ± 0,0095
LinearSVC, C = 0,3 (đã dò)	77,49%	0,7180 ± 0,0066

- Cross-validation 5-fold phân tầng trên 15.997 dòng huấn luyện, class_weight balanced
- Lưới C theo macro-F1: 0,1 cho 0,7124 · 0,3 cho 0,7180 · 1,0 cho 0,7054 · 3,0 cho 0,6875
- LinearSVC hơn LogisticRegression 0,0010, nhỏ hơn độ lệch chuẩn giữa các fold: hai mô hình ngang nhau

Macro-F1 0,7161; lớp trung tính là điểm yếu

Lớp	Độ chính xác	Độ phủ	F1
Tiêu cực (1.400)	0,7458	0,7564	0,7511
Trung tính (682)	0,5270	0,5440	0,5354
Tích cực (1.918)	0,8715	0,8525	0,8619

- Tỉ lệ dự đoán đúng 76,62% và macro-F1 0,7161 trên 4.000 dòng, chấm một lần; độ chính xác là precision, độ phủ là recall
- Năm hạt giống 0 đến 4: 77,58% $\pm$ 0,44 và macro-F1 0,7200 $\pm$ 0,0037
- Trung tính: đúng 371/682; 203 bị gán tiêu cực, 108 bị gán tích cực

Ma trận nhầm lẫn, chuẩn hóa theo hàng



Tham số HDBSCAN quyết định hơn cả từ dừng

Chọn cụm	Cụm tối thiểu	min_samples	Chủ đề	Nhiều (-1)	Cụm lớn nhất
eom (mặc định BERTopic)	10	mặc định	23	735 (49,2%)	81 (5,4%)
eom	20	5	3	0 (0%)	1.359 (91,0%)
eom (chọn dừng)	15	1	26	497 (33,3%)	117 (7,8%)
leaf	10	mặc định	27	793 (53,1%)	80 (5,4%)
leaf	20	5	19	620 (41,5%)	94 (6,3%)

- Khảo sát trên 1.493 bình luận của tập dữ liệu (1.500 dòng đầu), không phải bình luận của một video thật
- Mặc định đẩy gần nửa vào nhiều; min_samples 5 gom 91% vào một cụm; 15/1 cân bằng nhất và là mặc định của ứng dụng
- Bật hay tắt từ dừng cho phép gán chủ đề giống hệt từng dòng, chỉ từ khóa đổi

Năm tab, ba nguồn dữ liệu, không cần API key để chấm

- **Ba nguồn:** Link YouTube (cần API key), Tập CSV, Dữ liệu mẫu
- **Năm tab:** Tổng quan, Chủ đề, Cảm xúc, Dữ liệu, Mô hình
- Bình luận và vector nhúng được cache; đổi tab hay lọc bảng không chạy lại
- Ảnh: 1.000 dòng mẫu, 23 chủ đề, 20,6% nhiều, 47,4% tích cực (tập huấn luyện, nên tỷ lệ cảm xúc lạc quan hơn thực tế)



150 bình luận sai, xếp theo hiện tượng ngôn ngữ

Hiện tượng	n	Tiêu cực	Trung tính	Tích cực
Cần ngữ cảnh chương trình	36	15	11	10
Thương cảm, tiếc nuối	31	11	9	11
Vừa khen vừa chê	23	7	12	4
Phủ định	19	6	6	7
Teencode ngoài từ điển	16	5	4	7
Tên riêng lẫn át hoặc mất emoji	11	4	4	3
Nhãn gốc đáng ngờ	7	3	2	2
Châm biếm, không dấu, khác	7	4	2	1

- Mẫu phân tầng từ 935 dòng sai; một người đọc, một lượt
- Lớp trung tính: dẫn đầu là vừa khen vừa chê (12 trong 50 dòng), đúng với $F1\ 0,5354$
- Mô hình học cả chủ đề và tên riêng làm tín hiệu cảm xúc, đúng trong miền này nhưng không chuyển được sang video khác

Pipeline chạy được, tái lập được, và biết mình yếu ở đâu

- Đủ năm bước của môn, mọi con số tái lập từ results/ bằng lệnh trong phụ lục báo cáo
- Macro-F1 0,72 trên tập kiểm tra và năm hạt giống; lớp trung tính (F1 0,5354) là giới hạn của cách tiếp cận TF-IDF tuyến tính
- Với chủ đề, tham số HDBSCAN quyết định kết quả nhiều hơn danh sách từ dừng
- **Tiếp theo:** giữ emoji làm token và đo lại theo cùng quy trình năm hạt giống; dùng vector câu cho hồi quy logistic hoặc tinh chỉnh PhoBERT ba lớp; tính coherence c_v để chọn cấu hình chủ đề theo số đo thay vì cảm nhận

Số đẹp thì dễ, số đọc lại được mới khó.

Câu hỏi

Nhóm em xin cảm ơn thầy và các bạn.

Mã nguồn, 146 kiểm thử và toàn bộ tệp kết quả nằm trong repo nộp kèm báo cáo. Ba slide phụ lục phía sau: tài liệu tham khảo, ví dụ số c-TF-IDF, và một kỹ thuật của BERTopic.

Tài liệu tham khảo

1. Slide môn CS221 Xử lý ngôn ngữ tự nhiên, TS. Đặng Văn Thìn, UIT, bài 3, 4, 5, 6.
2. Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. arXiv:2203.05794.
3. McInnes, L., Healy, J., Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. arXiv:1802.03426.
4. Campello, R. J. G. B., Moulavi, D., Sander, J. (2013). Density-Based Clustering Based on Hierarchical Density Estimates. PAKDD 2013, LNCS 7819.
5. Nguyen, D. Q., Nguyen, A. T. (2020). PhoBERT: Pre-trained language models for Vietnamese. Findings of EMNLP 2020.
6. Thẻ mô hình keepitreal/vietnamese-sbert, Hugging Face Hub.
7. pyvi 0.1.1; scikit-learn 1.9.1 (Pedregosa và cộng sự, JMLR 2011); Streamlit 1.64.0; BERTopic 0.17.4; tài liệu YouTube Data API v3.
8. Dữ liệu được cung cấp bởi dự án ATSH-ABSA (UIT), chỉ dùng cho mục đích học tập. Gói ATSH-NLP-20k.

c-TF-IDF: vì sao “hay” không bao giờ đứng đầu từ khóa

$W(t, c) = tf(t, c) \times \log(1 + A / f(t))$, với A là số từ trung bình của một cụm

Từ	Cụm 1	Cụm 2	Cụm 3	$f(t)$	$\log(1 + 10/f(t))$
hát	6	0	0	6	$\log(2,667) = 0,981$
hạng	0	6	0	6	0,981
quảng_cáo	1	1	6	8	$\log(2,25) = 0,811$
hay	3	3	4	10	$\log(2) = 0,693$

- Ba cụm, mỗi cụm 10 từ, nên $A = 10$; logarit tự nhiên
- Cụm 1: hát $6 \times 0,981 = 5,88$; hay $3 \times 0,693 = 2,08$; quảng_cáo 0,81. Cụm 3: quảng_cáo 4,87; hay 2,77
- hay có mặt ở cả ba cụm nên thành phần logarit thấp nhất, luôn đứng sau từ đặc trưng riêng. Hư từ như là, của, mà có tần suất thô quá cao nên vẫn cần danh sách từ dừng

Bầy BERTopic với tiếng Việt và cách tái lập kết quả

- BERTopic() mặc định language="english"; nếu không truyền embedding_model, bước làm sạch nội bộ xóa mọi ký tự ngoài [A-Za-z0-9] trước c-TF-IDF: *không* thành *khng*, *chương_trình* thành *chngtrnh*
- Pipeline của nhóm luôn truyền mô hình nhúng vào BERTopic, kể cả khi vector đã tính sẵn; một kiểm thử xác nhận language của mô hình là None
- Tái lập: python src/train_sentiment.py (khoảng 12 giây, sinh lại results/ và models/); python experiments/dataset_stats.py, ab_preprocess.py, topic_ablation.py cho ba bảng thực nghiệm; pytest chạy 146 kiểm thử trong khoảng 16 giây
- Lệnh gom cụm dòng lệnh trên 1.500 dòng đầu cho 1.493 bình luận hợp lệ, 26 chủ đề, 33,3% nhiễu; UMAP có hạt giống cố định nên cùng máy cho cùng kết quả